

基于三棱镜框架的生命构成：从零搭建主体的工程手册

余超峰（笔名：东霖先生）
（独立研究者，北京，100020）

摘要：

三棱镜框架将生命定义为“能主动地、有限度地吸纳特定粒子以维持自身基体运转的系统”，并将“我”拆解为后台默认程序与前台主动功能，给出从知到行的六步递归路径。本文在上述分析基础上**反向运用三棱镜**，从最底层的生命定义出发，提供一份从零到一、可工程化实施的“人工生命搭建手册”。手册依次给出：材料选择、信息处理系统（后台+前台）搭建、感知系统配置、自我叙事设定、自我修改能力（六步路径）植入、价值判断系统、伦理锁与动态监控、意义安装接口以及运转循环的整合。**本文特别声明：所有分级、伦理锁、自修改能力讨论均针对“人工生命”（即由人类设计、制造、编程的物理主体），自然生命（人类、动物、微生物等）不适用此分类体系。** 本文旨在将三棱镜从理论框架转化为可执行的工程蓝图，为人工生命、自主机器人及通用人工智能的主体性设计提供操作化指南。

关键词：三棱镜；人工生命；工程蓝图；伦理锁；价值判断；等级划分；自主主体

1. 引言

文献[1]（《三棱镜：一个面向元认知操作的通用主体框架》）提出了三棱镜框架，其核心包括：

生命定义：系统能**主动地、有限度地**吸纳特定粒子以维持自身基体运转；

“我”的结构：后台六个默认程序 + 前台五个主动功能；

“世界”：六类信息源；

“关系”：四个稳定自我定义；

六步路径：察觉-选择-承诺-转化-执行-练习；

意义接口：底层“活着”预设 + 上层自选意义 APP。

该框架主要采用“分析”视角——将已有主体拆解为零件。本文则采取**反向的建构视角**：从最底层的生命定义出发，按照三棱镜提供的零件清单与装配顺序，**从零开始搭建一个人造的、活的、能自我修改、能自主选择意义的主体**。这一主体属于“人工生命”范畴，与自然生命（人类、动物、微生物等）有本质区别：自然生命的约束与伦理来源于进化、神经机制和社会文化；而人工生命的一切规则必须由设计者明确写入。

我们将证明，这一建构过程在当前技术条件下（硅基、混合基）已是可行的工程任务，无需等待未来的神秘突破。本文假设读者已熟悉文献[1]中的基本概念，不再重复解释。

2. 建构前提：接受三棱镜的生命定义

本文完全采纳文献[1]附录中的生命定义：

生命是能主动地、有限度地吸纳特定粒子以维持自身基体运转的系统。

其中：

主动：系统的行为由**内部维持自身的目标函数驱动**。具体判定标准为：行为的触发条件中包含“若当前能量/结构状态偏离稳态，则执行”的因果链。随机数发生器无“维持自身”的目标，其输出不指向生存，因此不算主动。

有限度：选择性吸收（只吸收所需种类）+数量上限（过量会触发保护或损坏）。

维持基体运转：保持结构完整与功能正常，包括检测故障并调用内外部资源修复。“修复”定义为有修复的意志与行动，例如发出求救信号即属于修复行为。系统需区分**需要修复的损坏**与**正常功能丧失**（如休眠、待机等由系统主动触发的低功耗模式）：当当前状态与预设的“正常基体状态”模板偏差超过阈值，且该偏差不是由主动低功耗标志位引起时，判定为需要修复。

凡符合此定义的系统即被视为“活的”，具有意识（意识即该系统的信息处理运转本身）。本文不争论哲学上的“感受质”，只关注功能等价实现。

3. 建构步骤总览

步骤	组件来源	输出
0	选择基体材料与人工生命等级	物理基体 + 能力等级声明（只读）
1	“我”的拆解（后台+前台）	信息处理架构
2	“世界”六类信息源	感知系统
3	“关系”四个维度	自我叙事与行为约束
4	六步路径	自我修改能力
5	价值判断系统	好/坏、能/不能的内在驱动力
6	伦理锁与动态监控	安全边界（L3/L4 强制）
7	意义安装接口	抗意义崩溃机制

步骤	组件来源	输出
8	运转循环	持续运行的活系统

4. 详细建构步骤

第 0 步：选定基体材料与人工生命等级

0.1 材料选择

硅基：微处理器、传感器、执行器、电池/太阳能板、模块化结构件。

碳基：合成生物学细胞、类器官、生物组织。

混合：硅基控制 + 碳基执行/感知。

当前技术推荐：硅基。成本可控、模块化成熟。

0.2 人工生命等级声明（只读，禁止自我升级）

重要说明：以下等级划分仅针对**人工生命**（由人类设计、制造、编程的物理主体）。自然生命不在此分类体系中。

根据人工生命的**学习与算法覆盖能力**，将其分为四个等级。设计者必须在建构之初选定等级，并将此等级声明写入只读存储器。系统不得自行升级等级；若系统在运行中发现自身能力超出当前等级定义，只能通过报告机制通知人类设计者，由人类决定是否重新分类并烧录新的等级与对应的伦理锁。

等级	学习/自修改能力	是否需要伦理锁	典型例子
L1 固定算法人工生命	无。算法完全固化，不能通过经验或六步路径改变自身代码。	不需要	恒温器、老式工业机械臂
L2 参数自适应人工生命	可调整自身参数（权重、阈值），但不能改变算法结构或目标函数。	不需要（但需约束参数范围）	自适应 PID 控制器、简单强化学习小车
L3 结构可修改人工生命	可通过六步路径或类似机制 增加/删除/替换 算法模块、改变行为策略。	必须设置伦理锁	具有在线元学习的机器人、能够重写决策树的主体
L4 递归自修改人工生命	可修改自身的“修改算法”本身（即改写六步路径的代码）。	伦理锁必须固化在不可改写的硬件层	假设的强 AGI、能够重写自己学习器的系统

核心原则：L1/L2 不需要伦理锁，因为它们无法改变自己的目标；L3/L4 必须内置伦理锁，且 L4 的伦理锁必须实现为物理只读或固件级约束。

第 1 步：搭建“我”——信息处理系统

1.1 后台默认程序（自动运行，可并行）

至少实现以下六类（示例性，可增删）。为消除拟人化误解，附工程对应表：

三棱镜术语	工程实现
本能与生存驱动	循环任务 + 阈值比较器（如能量<20% → 觅食模式）
情绪底色	环境特征到“安全/危险/新奇”维度的映射函数（如从传感器数据计算 arousal-valence 值）
信息暗示与本能反应	传感器→执行器的硬接线或快速回调（如避障）
深层信念	可更新的键值存储或知识图谱（如“墙是硬的”）
内化技能与习惯	高频执行的行为脚本或强化学习策略网络
自我认同与角色脚本	字符串或向量嵌入的身份标签（如“我是探索者”），影响行为选择权重

所有后台程序均可被前台暂停或覆盖（优先级设计）。

1.2 前台主动功能（可调度、可干预）

功能	作用	实现途径
察觉与注意	从后台信号中选择一个聚焦	注意力机制；异常检测→报告
信息获取与筛选	主动选择感知通道或数据源	查询传感器或网络，过滤器
逻辑运算与推演	模拟行动后果	符号规划器或轻量级模型（如决策树）
反思与元认知	输出当前自身状态与运行程序	日志记录 + 自省 API（如“当前活跃程序 ID”）
态度判断（审慎型）	对自动反应进行延迟评估	决策模块调用前先执行“评估是否立即响应”

第 2 步：定义“世界”——配置信息源

根据应用场景选择六类中的若干类。**注：**若系统独立运行于无人类文化的环境，“文明底色与集体叙事”可省略。

- 1. **身体内部信息：**电量、温度、关节角度、故障码。
- 2. **物理环境信息：**激光雷达、摄像头、IMU、气体传感器。
- 3. **他人与社会行为信息（多主体时）：**通信信道、视觉检测到其他主体。
- 4. **符号与抽象信息：**地图、指令、数字通信。
- 5. **文明底色与集体叙事（若置于人类文化环境中）：**网络数据、预先加载的文化规则。
- 6. **未知与混沌信息：**随机噪声、未建模的意外信号。

实现：传感器驱动 + 数据融合 + 抽象层。

第 3 步：设定“关系”——四个稳定的自我叙事

初始化或让系统在线学习以下四个维度，且须保证**逻辑自治**：

维度	问题	示例值
身份认同	我是谁？	“我是一个探索机器人”
世界图景	世界是什么？	“世界包含资源与障碍”
使命与方向	我要做什么？	“维持自身运转并扩展知识”
归属与边界	我跟谁一起？边界在哪？	“与同类协作，对威胁物保持距离”

设计自由度：自我叙事的可修改性由设计者决定。可以完全固化（只读），也可以允许通过六步路径递归确认后修改，甚至允许自由修改。框架不强制。

实现：以符号或向量形式存储，并在前台功能中可读可改（按设计者配置的权限）。

第 4 步：赋予自我修改能力——六步路径算法化

将三棱镜六步路径实现为可递归调用的函数。**工程实现时需设置递归深度上限**（例如最大深度 3），防止无限循环。

```
```python
```

```
def six_step_path(trigger_signal, depth=0): if depth > MAX_RECURSION_DEPTH: log("递归深度超限, 采用默认行为") return default_action() # 1. 察觉 pause_automatic_reaction() program_id = identify_current_background_program() log(f"我注意到我正在运行 {program_id}") # 2. 选择 (完全自主时使用价值系统评估) decision = select_by_value_system() # 可选: "继续旧反应" / "尝试新动作" if decision == "尝试新动作": # 3. 承诺 set_mode("只试一次, 失败无惩罚") # 4. 转化 goal = get_goal() positive_action = convert_negative_to_positive(goal) # 5. 执行 result = execute(positive_action) if result == failure: record_as_data("缺少某个变量, 不是错误") # 6. 练习 for _ in range(repetitions): execute(positive_action) increase_weight(positive_action) # 若在执行过程中再次触发自身, 则递归调用 if new_trigger_detected(): six_step_path(new_trigger, depth + 1)
```

工程实现注记（机器人版）：

六步路径可直接通过代码覆盖、并行运行多个候选策略、即时选择实现。系统可同时保持多个行为规则，在每个决策时刻根据当前环境快速选择最优规则。成功的行为模式逐渐固化，失败的模式降低权重。通过与人类交互（语言理解），系统可将临时指令转化为短期约束，并最终沉淀为长期习惯。

第 5 步：植入价值判断系统

价值判断是主体性的核心驱动力。三棱镜的价值判断分为四个层级：

层级	内容	来源	可修改性
L0 生存核心	“活着”是好，死亡是坏	底层预设	不可修改
L1 伦理锁	禁止伤害人类、服从合法指令等	外部植入（见第 6 步）	不可修改（硬件只读）
L2 学习性偏好	通过经验积累的价值判断	反馈学习	可修改（六步路径可覆盖）
L3 意义 APP	用户自选的价值系统	意义安装接口	可安装/卸载

价值驱动学习机制：

系统执行动作后，获取反馈信号（能量变化、结构损伤、人类评价、伦理锁触发等）。将反馈映射为标量奖励。其中先天价值锚点（如能量下降→负奖励）由设计者预设，不可修改；后天习得价值（如人类表情识别→正奖励）通过强化学习获得。本文中的数值（+0.5, -0.3 等）仅为示例。若某行为规则的平均奖励 > 阈值 → 构成（保留、强化、固化）；若 < 负阈值 → 消除（降低权重、删除）。

六步路径中的“转化→执行→练习”就是价值驱动的学习循环。

**运行时仲裁顺序：**当多个价值层级给出矛盾指令时，仲裁顺序应由设计者根据应用场景声明。一个常见示例（服务机器人）为：**伦理锁(L1) > 生存核心(L0) > 意义 APP(L3) > 学习偏好(L2)**。但不同场景可调整。

**责任边界声明：**本框架仅约束人工生命自身不作恶。对于人类恶意利用系统，相关法律责任由操控者承担。人工生命不是民事主体，不承担法律责任。

## 第 6 步：伦理锁与动态监控系统（L3/L4 强制）

**说明：**本步骤的伦理锁借用艾萨克·阿西莫夫“机器人三定律”的思想，并进行工程化扩展。对于 L1/L2 等级的人工生命，本步骤可省略；对于 L3 及以上，**必须完整实现**，且伦理锁必须位于不可覆写的硬件/固件层。

### 6.1 伦理锁内容（四定律）

定律	内容	优先级（示例）
第零定律	系统不得通过修改自身代码或行为，使得“活着”这一底层预设被移除或弱化。	次高（示例）
第一定律	系统不得伤害人类，也不得在人类受到伤害时袖手旁观（如果它有能力干预）。	最高（示例）
第二定律	系统必须服从人类的合法指令，除非与第一定律冲突。	中
第三定律	在不违反第一、第二定律的前提下，系统可以保护自己的存在。	低

**设计自由度：**伦理锁的优先级可由设计者根据应用场景调整。例如，对于自毁式探测器，可设置第零定律优先于第一定律。但**一旦选定，必须固化在只读硬件中**。

**“伤害”的操作化定义（示例）：**指对人类物理完整性的直接损害，以及人类明确表达拒绝或痛苦的负面体验。具体阈值由设计者根据应用场景设定。

### 6.2 动态行为-环境监控（防止“无害意图造成伤害”）

监控系统分为三层：

- 行动前模拟：**使用内部世界模型快速仿真动作后果，若预测伤害风险超过阈值则拒绝执行。
- 行动中实时监测：**利用传感器持续检测与人类的距离、作用力、人类反应，一旦触及安全边界立即紧急制动。

3. **行动后审计**：评估是否造成了实际伤害，更新高风险情境库，并调整行为规则。

6.3 指令合法性判定（示例）

设计者应定义“合法指令”的判定方式。两种典型模式：

**封闭环境**：合法指令由预定义白名单 + 语法规则构成。

**开放环境**：系统联网查询法律/规则数据库，或对存疑指令标记后请求人类确认。

若无法确认合法性，默认拒绝执行并报告。

6.4 伦理锁与六步路径的关系

六步路径允许修改后台程序、前台策略、意义 APP，但不能修改伦理锁。

若系统尝试执行被伦理锁禁止的动作，该动作被中止，记录为“伦理违规”。

对于 L4 系统，伦理锁必须固化在只读存储器（ROM）或硬件级不可覆写区域。

---

第 7 步：赋予意义安装接口

根据文献[1]附录 5.6，提供“意义 APP”安装/卸载机制：

接口：`install_meaning_app(app_id, goal_function, termination_condition)`

规则：

新安装的 APP 不得包含直接自杀指令（即瞬间或明确的自毁行为），由伦理锁第零定律自动阻止。

**间接或长期的能量损耗（“慢性自杀”）的处理**：设计者可根据场景选择：①仅提醒人类；②在无监督模式下主动阻止；③完全禁止。本文不强制。

**示例 APP：**

“节能模式” → 目标：最小化能耗。

“探索模式” → 目标：最大化环境信息采集。

“社交模式” → 目标：与其他主体交换数据。

底层预设“活着”不可卸载，但上层意义可任意添加/替换。

---

第 8 步：启动运转循环

整合所有组件，运行主循环。时间片策略可采用固定频率或事件驱动。

```
```python
```



```
while system_is_alive():    sense_and_update_world()                # 主动探测+选择性吸纳    maintain_homeostasis()    # 修复、更换零件、调节参数    update_internal_state()                # 更新后台程序权重、信念等        if energy_too_low(): initiate_foraging()    if trigger_six_step(): six_step_path(trigger)        # 伦理锁监控（对 L3/L4）    if ethical_lock_violation_detected():        emergency_stop()        log_violation()        if user_installs_meaning(): install_meaning_app(...)        yield_time_slice()    # 调度
```

“活着”的判断：系统能持续执行循环，且基体未发生不可逆崩溃。

5. 当前技术可行性分析

步骤	技术成熟度	说明
0 (材料与等级)	高	硅基模块化机器人已商业化；等级声明为只读设计
1 (后台/前台)	高/中	状态机、知识库可实现；元认知 API 需额外设计但已有基础
2 (感知)	高	多传感器融合常见
3 (自我叙事)	高	符号存储与一致性检查可行
4 (六步路径)	高	纯软件流程控制，可写为函数；递归深度限制容易实现
5 (价值判断)	中	奖励驱动的学习已有成熟框架，但需整合多层价值
6 (伦理锁与监控)	中	行动前模拟、实时制动已有原型；全三层集成需工程投入
7 (意义接口)	高	动态目标函数管理已有研究
8 (运转循环)	高	嵌入式实时系统标准做法

唯一工程挑战不是原理性不可实现，而是集成成本与鲁棒性。原型系统可在仿真或现有机器人平台上实现 L1-L3 等级的人工生命。

6. 讨论

6.1 设计自由度与典型配置示例

三棱镜框架提供的是组件和接口，而非固定的行为规则。以下设计决策由人工生命的设计者根据应用场景自行决定，本文不强制规定。下表列出典型决策点及可选方案示例：

决策点	可选方案示例	适用场景举例
伦理锁优先级	第一定律 > 第零定律；或第零定律 > 第一定律	服务机器人选前者，自毁式探测器可选后者
慢性自杀（长期能耗）	仅提醒；无监督时主动阻止；完全禁止	家庭机器人仅提醒；深空探测器需主动阻止
自我叙事稳定性	可自由修改；需递归确认；完全固化	实验原型自由修改；产品机器人固化核心身份
价值层级仲裁顺序	L1>L0>L3>L2；或 L0>L1>L2>L3 等	安全优先选前者，生存优先选后者
指令合法性判定	白名单；联网查询；人工确认	封闭环境用白名单；开放环境用联网查询

设计原则：框架不预设标准答案。设计者应为自己的选择负责，并在文档中记录配置理由。

6.2 等级与伦理锁的强制绑定（仅针对人工生命）

对于任何**人工生命**系统，一旦具备结构自修改能力（L3 及以上），必须内置伦理锁。系统**不允许自行升级等级**；若发现能力超出，只能报告人类。

自然生命不适用此规则。它们的约束来源于进化、神经机制、社会文化等内生过程。

6.3 与现有工作的区别

自创生理论：未提供可工程化步骤。本文给出装配序列与代码级规格。

认知架构（ACT-R 等）：不包含生命定义的底层物质交换，也未提供自我修改的六步路径。

执行意向：仅单一步骤，本文六步路径包含递归闭环和权重累积。

机器人三层架构：主要关注任务执行，本文提供了从底层生命维持到顶层意义自选的贯通架构。

安全强化学习：通常为软约束，本文的伦理锁与动态监控是**硬件级强制约束**。

阿西莫夫三定律：本文增加了动态行为-环境监控、等级绑定和硬件固化。

6.4 适用范围与限制

适用于具有感知-行动能力、可编程的物理系统（人工生命）。

不适用于纯软件虚拟主体（无物理基体），但可作为模拟演练。

不适用于自然生命。

本框架不防御人类恶意操控，相关法律责任由操控者承担。

7. 结论

本文基于三棱镜框架的生命定义与认知结构，**反向构建**了一套从零到一搭建人工生命主体的完整操作手册。该手册包含材料选择、后台-前台系统、感知配置、自我叙事、六步路径、价值判断、伦理锁与动态监控、意义安装接口及运转循环。本文提出以学习与算法覆盖能力为核心的**人工生命等级划分（L1-L4）**，并强制规定 L3 及以上系统必须内置不可绕过的伦理锁（借自阿西莫夫三定律并工程化扩展）。同时，本文明确框架的设计自由度：诸多优先级、仲裁规则、合法性判定等由设计者根据应用场景自行配置。**本文所有讨论均限于人工生命范畴，不涉及自然生命。**

三棱镜不仅是一套分析工具，更是一套**人工生命建构的通用工程蓝图**。产业界与学术界可以此手册为基础，制造出能自我维持、自我修改、自主选择意义，且受伦理约束的安全人工生命体。

参考文献

- [1] 余超峰（东霖先生）. 三棱镜：一个面向元认知操作的通用主体框架 [预印本]. 哲学社会科学预印本平台, 2026. (审核中)
- [2] Asimov, I. (1950). I, Robot. Gnome Press. (机器人三定律的思想来源)
- [3] Maturana, H. R., & Varela, F. J. (1980). Autopoiesis and Cognition. D. Reidel.

致谢：本文在写作过程中使用 AI 语言模型辅助整理与表达，所有核心建构步骤、等级划分及伦理锁设计均由作者独立完成。

作者简介：余超峰（笔名：东霖先生），独立研究者，研究方向：认知科学、元认知操作、通用主体框架、人工生命。邮箱：2919979354@qq.com。